

Implementasi Transfer Learning Menggunakan Arsitektur MobileNetV2 untuk Deteksi Kantuk Pengemudi



Oleh:

Brian Aditya Hermansyah (NIM: L200180116)

Huan Wendy Ariono (NIM: L200180086)

Arya Mukti A'raafi Zha Putra (NIM: L200180051)

**FAKULTAS KOMUNIKASI DAN INFORMATIKA
UNIVERSITAS MUHAMMADIYAH SURAKARTA
KOMUNIKASI DAN INFORMATIKA
MEI 2021**

HALAMAN PENGESAHAN

Laporan praktek kerja nyata dengan judul “ IMPLEMENTASI TRANSFER LEARNING MENGGUNAKAN ARSITEKTUR MOBILENETV2 UNTUK DETEKSI KANTUK PENGEMUDI” ini telah diperiksa, disetujui dan disahkan pada :

Hari : Sabtu

Tanggal : 22 Juni 2021

Dosen Pembimbing

Pembimbing Lapangan

(Dimas Aryo Anggoro, S.Kom., M.Sc.) (Dimas Aryo Anggoro, S.Kom., M.Sc.)
NIK : 1811

Mengetahui,

Ketua Program Studi
Informatika UMS

Heru Supriyono, S.T., M.Sc., Ph.D.
NIK : 970

ABSTRAK

Transportasi merupakan kebutuhan bagi masyarakat yang mana digunakan untuk berpindah antar daerah maupun pulau. Terdapat berbagai macam transportasi umum baik melalui laut, darat, dan udara. Transportasi udara dengan pesawat relatif cepat, tetapi transportasi darat dan laut seperti mobil, kereta api, bus, dan kapal banyak dijadikan pilihan sebab biaya yang relatif terjangkau. Biasanya transportasi darat dan laut memakan waktu yang banyak. Kebanyakan penumpang akan tidur selama perjalanan, namun tidak berlaku untuk pengemudi. Pengemudi diharuskan untuk tetap fokus dan tidak mengantuk saat perjalanan yang memakan waktu yang banyak agar sampai di tujuan dengan selamat.

Karena itu dibutuhkan suatu metode yang dapat mengidentifikasi kantuk dengan cepat dan akurat sehingga dapat digunakan untuk memeriksa keadaan pengemudi saat sedang melakukan perjalanannya. Hal ini penting untuk mengurangi angka kecelakaan karena di Indonesia setiap tahunnya terjadi lebih dari 60.000 kecelakaan yang mengakibatkan sekitar lebih dari 12.000 orang mati yang artinya terdapat 33 orang mati perharinya. Tujuan penelitian ini adalah merancang metode deteksi kantuk saat perjalanan durasi panjang. Metode yang diimplementasikan pada penelitian ini adalah algoritma *convolutional neural network* dapat digunakan untuk mengidentifikasi obyek dalam bentuk citra digital. Kemudian untuk meningkatkan waktu *training*, diterapkanlah *transfer learning* dengan arsitektur MobileNetV2 yang berbasis *convolutional neural network*.

Target luaran dari penelitian ini adalah Laporan hasil penelitian guna untuk memenuhi Praktek Kerja Nyata.

Kata kunci: Convolutional Neural Network, Deteksi Kantuk, Image Processing, Kecelakaan Lalu Lintas, Kelelahan Berkendara, MobileNetV2, Transfer Learning.

1. LATAR BELAKANG

Transportasi merupakan kebutuhan bagi masyarakat yang mana digunakan untuk berpindah antar daerah maupun pulau. Terdapat berbagai macam transportasi umum baik melalui laut, darat, dan udara. Transportasi udara dengan pesawat relatif cepat, tetapi transportasi darat dan laut seperti mobil, kereta api, bus, dan kapal banyak dijadikan pilihan sebab biaya yang relatif terjangkau. Biasanya transportasi darat dan laut memakan waktu yang banyak. Kebanyakan penumpang akan tidur selama perjalanan, namun tidak berlaku untuk pengemudi. Pengemudi diharuskan untuk tetap fokus dan tidak mengantuk saat perjalanan yang memakan waktu yang banyak agar sampai di tujuan dengan selamat.

Karena itu dibutuhkan suatu metode yang dapat mengidentifikasi kantuk dengan cepat dan akurat sehingga dapat digunakan untuk memeriksa keadaan pengemudi saat sedang melakukan perjalanannya. Hal ini penting untuk mengurangi angka kecelakaan karena di Indonesia setiap tahunnya terjadi lebih dari 60.000 kecelakaan yang mengakibatkan sekitar lebih dari 12.000 orang mati yang artinya terdapat 33 orang mati perharinya. Tujuan penelitian ini adalah merancang metode deteksi kantuk saat perjalanan durasi panjang. Metode yang diimplementasikan pada penelitian ini adalah algoritma *convolutional neural network* dapat digunakan untuk mengidentifikasi obyek dalam bentuk citra digital. Kemudian untuk meningkatkan waktu *training*, diterapkanlah *transfer learning* dengan arsitektur MobileNetV2 yang berbasis *convolutional neural network*.

Saat ini, klasifikasi citra digital dapat di implementasikan pada berbagai bidang tak terkecuali bidang transportasi. Dengan menggunakan klasifikasi citra kita dapat mengidentifikasi inputan citra ke dalam berbagai macam kategori. Yaitu mengidentifikasi mata apakah dalam keadaan terbuka atau tertutup untuk mendeteksi apakah pengemudi dalam keadaan sadar atau tidak.

Metode *deep learning Convolutional* yaitu salah satunya adalah *Neural Network (CNN)* yang mana sering dimanfaatkan untuk melakukan pendeteksian dan pengenalan dalam sebuah citra digital yakni objek. Belakangan ini *deep learning* telah menunjukkan pencapaian yang menakjubkan. Semua itu dipengaruhi oleh faktor komputasi yang lebih mumpuni, *dataset* yang

berlimpah dan teknik yang digunakan untuk melatih jaringan yang lebih dalam (Goodfellow, Bengio, Y, dan Courville, A., 2016). Pencapaian CNN diakui sebagai salah satu model termuktahir dalam menyelesaikan permasalahan *object detection* dan *object recognition*. Pada tahun 2012, dari hasil penelitian terhadap CNN dapat disimpulkan bahwa CNN dapat melakukan pengenalan citra digital dengan akurasi yang menyaingi manusia pada *dataset* tertentu (Coates et al., 2011).

Akan tetapi, kekurangan proses training model CNN membutuhkan waktu dan sumber daya komputasi yang cukup banyak. Akibatnya, jika data besar dan berjumlah banyak maka proses training dapat berjalan dengan sangat lama. Oleh karena itu, metode transfer learning akan digunakan dalam penelitian ini yang bermanfaat untuk mengurangi waktu pada proses training. Berdasarkan penelitian yang dilakukan oleh Sandler et al. (2018), terdapat sebuah arsitektur transfer learning yang efisien yaitu MobileNetV2. Metode ini relatif lebih cepat apabila dibandingkan dengan metode transfer learning lainnya, seperti: SSD, YOLO, Faster-RCNN, RFCN, NasNet, dan MobileNet. Bahkan, MobileNetV2 dapat ditanam pada perangkat yang memiliki sumber daya yang lebih kecil, contohnya: ponsel dan CCTV. Sehingga, diharapkan implementasi MobileNetV2 akan dapat melakukan proses klasifikasi citra mata untuk deteksi kantuk sopir dengan waktu yang relatif cepat.

2. TUJUAN

- Konsentrasi penelitian ini adalah tentang bagaimana mengklasifikasikan citra mata untuk deteksi kantuk pengemudi, sehingga dapat mengklasifikasikan inputan citra ke dalam beberapa kategori tertentu. Yaitu mengidentifikasi mata apakah dalam keadaan terbuka atau tertutup untuk mendeteksi apakah pengemudi dalam keadaan sadar atau tidak. Penelitian ini didasari dari metode *deep learning* menggunakan CNN dengan arsitektur MobileNetV2, yang diklaim lebih cepat daripada CNN konvensional, untuk membantu mengenali kondisi mata.
- Target penelitian ini adalah sebuah algoritma yang memiliki akurasi yang cukup tinggi, yaitu >80%, sedangkan waktu pemrosesan yang diperlukan lebih sedikit dibandingkan implementasi CNN konvensional.
- Luaran dari penelitian ini adalah sebuah kode program yang dapat mengklasifikasi mata untuk deteksi kantuk sopir berdasarkan citra yang dimasukkan.

3. TINJAUAN PUSTAKA

a. Mata Mengantuk

Mengantuk merupakan salah satu keadaan dimana tubuh membutuhkan istirahat atau tidur. Penyebab seseorang mengantuk sangatlah banyak tapi kebanyakan disebabkan karena kelelahan. Mengantuk juga dapat disebabkan apabila kita melakukan suatu kegiatan secara berulang-ulang dan dilakukan dalam durasi yang lama misalnya saja mengemudikan kendaraan ketika sedang melakukan perjalanan jauh. Saat mengantuk kelopak mata kita akan terasa berat kedipan mata orang normal yang sedang tidak mengantuk adalah sekitar 15 sampai 20 kali permenit. Kita dapat mendeteksi seseorang mulai mengantuk atau tidak dengan melihat jumlah kedipan mata apabila frekuensinya menurun hingga 3 kali atau kurang setiap menitnya kita dapat menyimpulkan bahwa pengemudi sedang mengantuk. Ada banyak hal yang dapat digunakan untuk menentukan apakah pengemudi sedang mengantuk atau tidak salah satunya dengan cara mengamati kondisi normal posisi kelopak mata membuka lebar sebelum menutup, namun ketika mengantuk jarak antara kedua kelopak mata semakin menyempit dan frekuensi kedipan mata semakin menurun hingga tertidur. (Kuswara, 2013).

b. Artificial Neural Network (ANN)

Berdasarkan penelitian yang dilakukan oleh (Nwankpa et al., 2018), Artificial Neural Network terdiri atas tiga layer utama – input layer, hidden layer, dan output layer. Input layer adalah suatu layer yang bertugas untuk menerima input data. Adapun data dapat berupa teks, gambar, suara, ataupun video. Setelah input layer menerima data, maka akan dilakukan training terhadap data tersebut di dalam hidden layer. Di dalam hidden layer ini, akan dihasilkan suatu model dari data yang telah dimasukkan dari hidden layer. Kemudian, model tersebut dapat digunakan untuk klasifikasi data yang telah masuk. Hasil dari klasifikasi akan dikeluarkan melalui output layer dengan adanya control dari Fungsi Aktivasi.

Fungsi Aktivasi adalah suatu fungsi yang mentransformasikan nilai yang didapatkan dari suatu unit menjadi suatu output. Seperti contoh pada klasifikasi, apabila nilai yang dihasilkan adalah sebuah data numerik, maka fungsi aktivasi akan sangatlah diperlukan untuk mentransformasikan data numerik tersebut menjadi suatu class. Salah satu Fungsi aktivasi yang digunakan pada penelitian tentang CNN adalah Rectified Linear Unit (ReLU). Berdasarkan penelitian yang dilakukan oleh Karlik dan Olgac (2011), fungsi aktivasi ini dapat meningkatkan ketepatan yang

dilakukan oleh model yang dihasilkan pada proses training. Adapun fungsi aktivasi ini akan menghasilkan linear model apabila nilai input $x \geq 0$. Sebaliknya, apabila nilai input $x < 0$, output yang akan dihasilkan adalah 0.

c. *Convolutional Neural Network (CNN)*

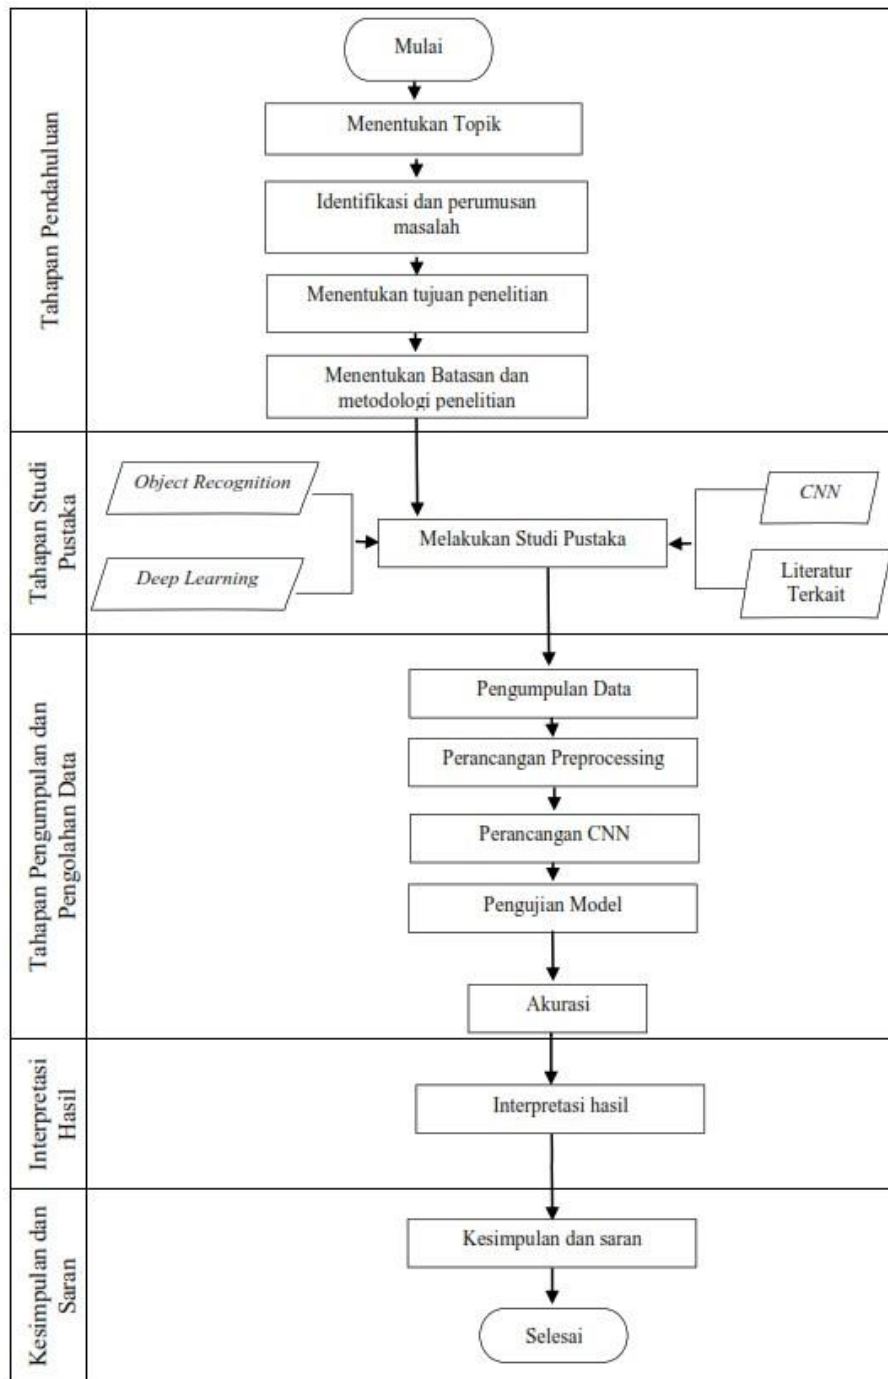
Salah satu bagian dari metode ANN yang mampu mendeteksi dan mengenali sebuah objek pada sebuah citra digital adalah *Convolutional Neural Network (CNN)*. Penelitian terkait CNN pernah dilakukan oleh Susanto dan Mulyono (2019). Pada penelitian tersebut, metode CNN diterapkan untuk rekognisi pada objek wayang kulit. Akurasi yang dihasilkan adalah 96% dengan empat jenis wayang yang berbeda e.g. Arjuna, Gatotkaca, Srikandi, dan Hanoman. Penelitian lain juga dilakukan oleh Hassan et al. (2019) menghasilkan bahwa CNN memiliki keakuratan paling tinggi (99%) untuk pengolahan citra dibandingkan dengan ANN (94%) dan SVM (91%).

d. Transfer Learning

Dalam implementasi CNN, proses training membutuhkan banyak data training untuk mempelajari pola data. Akibatnya, untuk mendapatkan suatu pola data, dibutuhkan waktu yang sangat banyak. Sehingga proses komputasi dapat berjalan dengan sangat lambat. Sedangkan jika jumlah data training tidak mencukupi, maka hasil analisis tidak akan valid. Solusinya kita dapat menggunakan jumlah data secukupnya. Terdapat beberapa teknik untuk membantu proses CNN tersebut dengan mengizinkan menggunakan data training yang lebih sedikit. Salah satu tekniknya adalah transfer learning. Transfer learning dapat mentransfer pengetahuan model jaringan saraf yang sudah terlatih lainnya ke model yang akan dibuat (Gultom et al., 2018). Salah satu model transfer learning yang dapat digunakan adalah MobileNetV2. Model ini dikatakan sebagai salah satu model yang efisien, dan sangat efektif apabila kita mengimplementasikan pada feature extractor untuk klasifikasi citra, pendeteksian dan segmentasi objek (Patel and Chaware, 2020).

4. METODE

Dibawah ini adalah diagram alir penelitian yang menggambarkan proses penelitian ini:




1. Pengumpulan Data Training dan Data Testing

Data set mata terbuka dan mata tertutup untuk testing dan training kami mengambilnya dari <http://mrl.cs.vsb.cz/eyedataset> dimana kami menggunakan perbandingan 70% untuk data training sedangkan 15% untuk data testing yang terdiri dari 2135 gambar mata terbuka dan 2135 gambar mata tertutup untuk data testing sedangkan untuk data training kami menggunakan 16750 gambar mata terbuka dan 16750 gambar mata tertutup. Data yang kami pakai merupakan data yang berasal dari web penyedia dataset.



Gambar 1. sample dataset mata tertutup



Gambar 2. sample dataset mata terbuka

2. Arsitektur MobileNetV2

Berdasarkan Michele et al. (2019), secara teknis arsitektur MobileNetV2 akan mengganti convolutional layer yang membutuhkan resource dan waktu pemrosesan yang tinggi. Dengan adanya depthwise separable convolutional blocks pada arsitektur MobileNetV2, convolutional block dapat dipisahkan secara mendalam. Disini, setiap blok terdiri dari 3 x 3 depthwise convolutional layer yang dapat melakukan filter input. Kemudian, layer berikutnya adalah sebuah 1 x 1 pointwise convolutional layer, yang menggabungkan nilai-nilai yang telah difilter untuk membuat sebuah fitur baru.

Pada MobileNetV2, tiap blok terdapat sebuah 1 x 1 expansion layer, sebagai tambahan dari depthwise dan pointwise convolutional layer. Pointwise convolutional layer pada MobileNetV2 dapat disebut sebagai sebuah projection layer, yang memproyeksikan data dengan jumlah channel

(saluran) citra yang banyak menjadi sebuah tensor dengan jumlah channel (saluran) citra yang jauh lebih sedikit.

Kemudian, terdapat residual bottleneck block memiliki output dari setiap blok yang merupakan bottleneck. Terdapat 1 x 1 expansion convolutional layer akan memperluas jumlah saluran (channel) citra tergantung pada faktor ekspansi dalam data sebelum memasuki the depthwise convolution. Selain itu, hal baru lainnya, dalam blok penyusun MobileNetV2 adalah berupa residual connection. Terdapat residual connection yang digunakan untuk membantu aliran gradien melalui jaringan. Setiap layer pada MobileNetV2 menerapkan batch normalization dan ReLU6 sebagai fungsi aktivasi. Namun, output dari projection layer tidak memiliki fungsi aktivasi. Arsitektur MobileNetV2 yang lengkap terdiri dari 17 residual bottleneck block, yang secara berurutan diikuti oleh regular 1x1 convolution, a global average pooling layer, dan classification layer seperti yang ditunjukkan pada Tabel 2.

Tabel 1. Layer pada Arsitektur MobileNetV2

Input	Operator	Faktor ekspansi (t)	Jumlah channel output (c)	Jumlah iterasi (n)	Stride (s)
224 x 224 x 3	Convolution 2D	-	32	1	2
112 x 112 x 32	Bottleneck	1	16	1	1
112 x 112 x 16	Bottleneck	6	24	2	2
56 x 56 x 24	Bottleneck	6	32	3	2
28 x 28 x 32	Bottleneck	6	64	4	2
14 x 14 x 64	Bottleneck	6	96	3	1
14 x 14 x 96	Bottleneck	6	160	3	2
7 x 7 x 160	Bottleneck	6	320	1	1
7 x 7 x 320	Convolution 2D 1x1	-	1280	1	1
7 x 7 x 1280	Average Pooling 7x7	-	-	1	-
1 x 1 x 1280	Convolution 2D 1x1	-	k	-	-

Secara konvensional, convolution menerima $h_i \times w_i \times d_i$ input tensor L_i , dan mengaplikasikan convolutional kernel $K \in \mathbb{R}^{k \times k \times d_i \times d_j}$ untuk menghasilkan sebuah $h_i \times w_i \times d_i$ output tensor L_j akan memiliki the computational cost sebesar $h_i * w_i * d_i * d_j * k * k$. Sedangkan pada depthwise separable convolutions – sebagai ganti dari standar convolutional layer – bekerja hampir sebaik convolutional layer standar, hanya saja computational cost yang dihasilkan sebesar $h_i * w_i * d_i(k^2 + d_j)$, sebagai jumlah dari depthwise and 1 x 1 pointwise convolution layer yang terdapat pada arsitektur.

Depthwise separable convolutions layer dapat mengurangi komputasi jika dibandingkan dengan standard convolutional layer sebesar K^2 . MobileNetV2 menggunakan $k = 3$ (3 x 3 depthwise separable convolutions), sehingga computational cost menjadi 8 atau 9 kali lebih kecil dibandingkan standard convolutions, dengan hanya mengurangi tingkat akurasi yang tidak signifikan.

3. Evaluasi

Pada penelitian ini, untuk mengevaluasi model metrik yang diimplementasikan adalah akurasi. sebelum kita membahas lebih lanjut, untuk memahami matriks yang diimplementasikan kami akan menjelaskan tentang true positive (TP), false positive (FP), false negative (FN) dan true negative (TN) hal ini sama dengan yang ditampilkan confusion matrix Tabel 2. TP merupakan data yang benar dan positif, sedangkan TN merupakan data benar tetapi negatif. Sedangkan FN bertolak belakang dengan TP yaitu data negatif yang diprediksi salah, dan FP adalah kebalikan dari TN yaitu data positif yang diprediksi salah.

Tabel 2. Confusion Matrix

Predicted Class	True Class	
	Positive	Negative
Positive	True Positive (TP)	False Positive (FP)
Negative	False Negative (FN)	True Negative (TN)

Akurasi didefinisikan sebagai rasio dari semua data yang diklasifikasikan dengan benar (baik yang positif maupun yang negatif) dibagi dengan jumlah total data.

$$accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

4. Rencana Target Capaian

Target penelitian ini adalah sebuah algoritma yang memiliki akurasi yang cukup tinggi, yaitu >80%, sedangkan waktu pemrosesan yang diperlukan lebih sedikit dibandingkan implementasi CNN konvensional.

5. Susunan Organisasi Tim Peneliti dan Pembagian Tugas

No	Nama / NIDN	Instansi Asal	Bidang Ilmu	Alokasi Waktu (jam/minggu)	Uraian Tugas
1	<u>Ketua Pengusul</u> Brian Aditya Hermansyah / L200180116	Universitas Muhammadiyah Surakarta	Informatika	4 Jam	<ul style="list-style-type: none"> ▪ Pengumpulan data ▪ Analisis data dan implementasi hasil ▪ Pengujian ▪ Penyusunan laporan
2	<u>Anggota Pengusul</u> Huan Wendy Ariono / L200180086	Universitas Muhammadiyah Surakarta	Informatika	4 Jam	<ul style="list-style-type: none"> ▪ Pengumpulan data ▪ Analisis data dan implementasi hasil ▪ Pengujian ▪ Penyusunan laporan

3	<u>Anggota Pengusul</u> Arya Mukti A'raafi Zha Putra / L200180051	Universitas Muhammadiyah Surakarta	Informatika	4 Jam	<ul style="list-style-type: none"> ▪ Pengumpulan data ▪ Deployment ▪ Pengujian ▪ Penyusunan laporan
---	--	--	-------------	-------	---

5. HASIL DAN PEMBAHASAN

Hasil yang dicapai dari penelitian ini adalah sebuah metode deteksi kantuk yang di implementasikan dalam kode program yang dapat mengklasifikasi mata untuk deteksi kantuk pengemudi berdasarkan citra yang dimasukkan. Kode program akan dijalankan di python yang mana sebagai prototipe dari penelitian ini dapat langsung digunakan dengan media input citra berupa kamera.

Dari penelitian yang telah kami lakukan diperoleh hasil akurasi 99% dengan menggunakan dengan arsitektur MobileNetV2. Berikut ini kami tampilkan informasi hasil prediksi kemudian membandingkannya dengan hasil aktual yang disajikan pada table *Confusion Matrix* sebagai berikut.

Table 3. Hasil perbandingan

Predicted Class	True Class	
	Positive	Negative
Positive	2113	22
Negative	15	2120

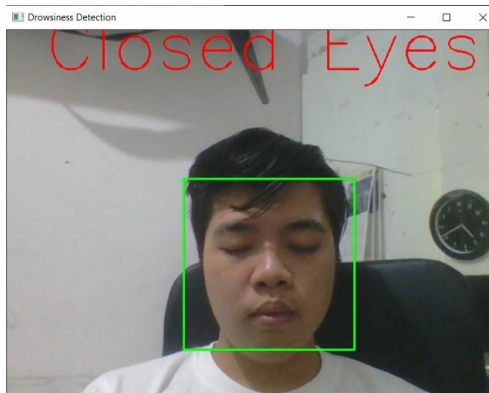
Accuracy in Validation set: 99.1%

Dibawah ini adalah screenshot prototype dari metode untuk mengklasifikasi mata yang mana prototype dibuat dengan menggunakan python yang dapat mendeteksi kondisi mata seseorang apakah sedang terbuka atau tertutup yang mana keterangan kondisi mata tersebut akan ditampilkan secara realtime di bagian atas dengan tulisan “Closed Eyes” berwarna merah disertai dengan suara

alarm (*gambar 4*) ketika mata sedang tertutup dan “Open Eyes” ketika mata sedang terbuka (*gambar 3*).



Gambar 3. Ketika mata terbuka



Gambar 4. Ketika mata tertutup

```
Python 3.7.0 Shell
File Edit Shell Debug Options Window Help
RESTART: E:\KULIAH SEMESTER 6\NAGANG\drowsiness_detection-master\testing.py
False
Eyes are not detected
False
False
Eyes are not detected
Eyes are not detected
False
Eyes are not detected
False
False
False
Eyes are not detected
False
False
False
Eyes are not detected
False
False
Eyes are not detected
Eyes are not detected
False
Eyes are not detected
False
Eyes are not detected
False
False
Eyes are not detected
Eyes are not detected
False
Eyes are not detected
False
False
Eyes are not detected
False
False
False
Ln: 506 Col: 4
```

Gambar 5. Screenshot program Ketika dijalankan

6. KESIMPULAN

Dari hasil penelitian yang diperoleh, bisa disimpulkan bahwa menggunakan arsitektur MobileNetV2 dapat memberikan prediksi citra mata untuk deteksi kantuk pengemudi dengan akurasi yang mendekati sempurna. Kemudian arsitektur MobileNetV2 memiliki performa yang sangat baik, ringan dan cepat dalam klasifikasi data mata, sehingga dapat membantu memprediksi secara cepat pengemudi yang mengantuk untuk menghindari kecelakaan yang diakibatkan kesalahan manusia.

REFERENSI

- Budianita, E., Jasril. (2015). Implementasi Pengolahan Citra dan Klasifikasi K-Nearest Neighbour untuk Membangun Aplikasi Pembeda Daging Sapi dan Babi. *Jurnal Sains, Teknologi dan Industri*, 242-247.
- Coates, A., Ng, A., & Lee, H. (2011, June). An analysis of single-layer networks in unsupervised feature learning. In *Proceedings of the fourteenth international conference on artificial intelligence and statistics* (pp. 215-223).
- Goodfellow, I., Bengio, Y, and Courville, A. (2016). Deep Learning (Adaptive Computation and Machine Learning Series). The IMT Press.
- Gultom, Y., Arymurthy, A. M., & Masikome, R. J. (2018). Batik classification using deep convolutional network transfer learning. *Jurnal Ilmu Komputer dan Informasi*, 11(2), 59-66.
- Hassan, M., Ullah, S., Khan, M. J., & Khurshid, K. (2019). Comparative Analysis of Svm, ANN and Cnn for Classifying Vegetation Species Using Hyperspectral Thermal Infrared Data. *ISPRS-International Archives of the Photogrammetry, Remote Sensing and Spatial Information Sciences*, 4213, 1861-1868.

- Karlik, B., & Olgac, A. V. (2011). Performance analysis of various activation functions in generalized MLP architectures of neural networks. *International Journal of Artificial Intelligence and Expert Systems*, 1(4), 111-122.
- Lukman, A. (2012). Implementasi pengolahan citra dan Algoritma LVQ Untuk Pengenalan Buku. Seminar Nasional Informatika, (hal. 145-155).
- Michele, A., Colin, V., & Santika, D. D. (2019). Mobilenet convolutional neural networks and support vector machines for palmprint recognition. *Procedia Computer Science*, 157, 110117.
- Nwankpa, C., Ijomah, W., Gachagan, A., & Marshall, S. (2018). Activation functions: Comparison of trends in practice and research for deep learning. *arXiv preprint arXiv:1811.03378*.
- Patel, R., & Chaware, A. (2020, June). Transfer Learning with Fine-Tuned MobileNetV2 for Diabetic Retinopathy. In *2020 International Conference for Emerging Technology (INCET)* (pp. 1-4). IEEE.
- Rahman, A., & Hermana, B. (2014). *Faktor yang Mempengaruhi Kelelahan Pengendara Mobil Pribadi*.
- Zein, A. (2018). Pendeteksian Kantuk Secara Real Time Menggunakan Pustaka OPENCV dan DLIB PYTHON. *Sainstech: Jurnal Penelitian Dan Pengkajian Sains Dan Teknologi*, 28(2). <https://doi.org/10.37277/stch.v28i2.238>
- Sandler, M., Howard, A., Zhu, M., Zhmoginov, A., & Chen, L. C. (2018). Mobilenetv2: Inverted residuals and linear bottlenecks. In *Proceedings of the IEEE conference on computer vision and pattern recognition* (pp. 4510-4520).

Susanto, A., & Mulyanto, I. U. (2019). REKOGNISI WAYANG KULIT MENGGUNAKAN JARINGAN SYARAF TIRUAN.